



Project Break EDA - Análisis Exploratorio de Datos del mercado laboral de Ciencias de Datos de 2025

Autores: Pablo Hernández Hernández y Maksym Chaika Palamaryuk

Fecha: Mayo 2026



Índice

1. Resumen ejecutivo
2. Introducción
3. Hipótesis
4. Metodología y dataset
5. Análisis exploratorio
 - 5.1. Análisis univariante
 - 5.2. Análisis bivariante
 - 5.3. Análisis multivariante
6. Conclusiones
7. Recomendaciones



1. Resumen ejecutivo

El objetivo de este estudio es analizar cómo influyen diferentes factores como el nivel educativo o la experiencia profesional sobre la empleabilidad y el salario de un científico de datos.

Los resultados muestran una relación directa con el nivel educativo, la experiencia laboral y técnica, al igual que la industria y la edad del profesional. En cuanto al uso de Inteligencia Artificial o ser autónomo, no tiene ninguna relación directa con el salario.

2. Introducción

El mercado laboral de los científicos de datos, y los futuros profesionales del mismo sector, es un entorno muy cambiante, el cual aparentemente crece sin cesar. Sin embargo, no existe la visibilidad suficiente sobre qué factores determinan las variables más comunes en él: el salario y la empleabilidad.

Por ello, mediante la encuesta anual de Stack Overflow Developer Survey 2025, que posee alrededor de 49.000 respuestas de desarrolladores alrededor del mundo sobre sus condiciones laborales y preferencias, se analizarán factores comunes dentro de un entorno laboral.

No obstante, de aquellas 49.000 respuestas y 172 preguntas interesan para este Análisis Exploratorio de Datos (EDA) las respuestas de los perfiles del sector de Ciencia de Datos, entre estos están los científicos, analistas e ingenieros de datos, al igual que los perfiles centrados en Inteligencia Artificial y Bases de Datos.

Luego, sólo interesan 13 de las preguntas respondidas, centradas en factores de un mercado laboral, como el salario anual, el nivel educativo, la experiencia, etc. El resultado son 3.000 registros de trabajo real.

3. Hipótesis

Tabla 1. Hipótesis EDA



Hipótesis		Enfoque análisis
H1	<i>A mayor edad, mayor salario anual</i>	Bivariante
H2.1.	<i>A mayor cualificación académica, mayor</i>	Bivariante
H2.2.	<i>empleabilidad</i>	Multivariante (exploratorio)
H3.1.	<i>A mayor experiencia profesional y técnica,</i>	Bivariante (exploratorio)
H3.2.	<i>mayor salario</i>	Multivariante
H4	<i>Los freelancers obtienen mayor retribución que los empleados</i>	Bivariante (exploratoria)
H5	<i>El uso de IA se asocia con mejores indicadores laborales</i>	Bivariante (exploratoria)
H6	<i>El sector o industria influye en el nivel salarial</i>	Bivariante

Fuente: Elaboración propia

4. Metodología y dataset

Comienza el análisis con la carga del archivo csv con los datos mencionados, tras visualizarlo detenidamente y explorarlo, se procede a seleccionar las columnas, que son las preguntas de la encuesta, y las filas centradas en las respuestas de los profesionales del sector de datos.

Después del filtrado, continúa la limpieza de filas duplicadas y valores nulos. En cuanto a los valores vacíos, las decisiones más importantes han sido eliminar el 43% de las filas con valores nulos en la pregunta sobre el salario, al ser una variable troncal, es imprescindible tener los datos más certeros en esta columna. Los datos sobre la edad son rangos de años, se mantiene como dato categórico debido a que el estudio no requiere cambio a numérico. Luego, a las preguntas con pocos valores vacíos se les ha imputado la moda o la mediana, respectivamente, dejando como referencia una columna con los valores que han sido nulos indicados con "True". Por último, cabe destacar el tratamiento del outlier de la columna de años de experiencia técnica, donde se ha eliminado el valor 100.



Como resultado existen 1741 respuestas válidas para el estudio, el Data Frame final sobre el que se ha trabajado es el siguiente:

Figura 1. Primeras filas del Data Frame.

ConvertedCompYearly	Age	EdLevel	WorkExp	YearsCode	Employment	AISelect	Industry	Country	JobSat	DevType	fue_missing_YearCode	fue_missing_WorkExp	fue_missing_Industry
8	25-34 years old	Bachelor	9.0	15.0	Employed	Yes	Banking/Financial Services	Ukraine	8.0	Data engineer	False	False	False
33	45-54 years old	Bachelor	24.0	26.0	Employed	No	Software Development	USA	8.0	Data engineer	False	False	False
45	45-54 years old	Professional	20.0	23.0	Employed	No	Software Development	Hungary	8.0	AI/ML engineer	False	False	False
68	45-54 years old	Bachelor	31.0	20.0	Freelancer	Yes	Computer Systems Design and Services	France	NaN	Data engineer	False	False	False
85	35-44 years old	Master	15.0	20.0	Employed	Yes	Software Development	Italy	7.0	AI developer	False	False	False


Fuente: Elaboración propia.

5. Análisis exploratorio

5.1. Análisis univariante

En el análisis de frecuencias de las variables categóricas se observa, en los gráficos 1 y 2, que la muestra está formada principalmente por personas de 25 a 44 años, que representan cerca del 69% del total. También destaca el alto nivel educativo de los encuestados, ya que más del 70% cuenta con estudios de máster o grado universitario.


Gráfico 1. Frequency of Age.





Fuente: Elaboración propia

Gráfico 2. Frequency of EdLevel.




Fuente: Elaboración propia

En cuanto a la situación laboral, la mayoría de los registros corresponden a personas empleadas, con un 84,32%. Además, el 78,12% respondió afirmativamente en la variable `AISelect`, lo que indica una presencia elevada de perfiles relacionados con el uso o selección de inteligencia artificial.

Respecto a la industria, predomina `Software Development`, con un 33,43%. A nivel geográfico, Estados Unidos es el país más representado, con un 25,50%, aunque el dataset incluye participantes de 104 países. Finalmente, los perfiles profesionales más frecuentes son `Data engineer`, `AI/ML engineer` y `Data scientist`.


Gráfico 3. Boxplot de ConvertedCompYearly



Fuente: Elaboración propia.

En el gráfico 3 se puede observar que existen outliers en el salario anual con valores extremos, sobrepasando 1 millón de dólares anuales. Esta información ha servido para que pueda ser tratado, como se ha mencionado anteriormente y finalmente obtener el siguiente gráfico.

Gráfico 4. Distribution of ConvertedCompYearly without outliers



Fuente: Elaboración propia.

El histograma muestra cómo se concentra la mayor parte de los datos en el primer rango de salario de 0 a 125 mil dólares anuales. Expresando una continuidad decreciente mientras más se acerca a valores elevados.

Figura 2. Tabla tendencia central



	count	mean	median	std	min	max	range
ConvertedCompYearly	1741.0	101999.477312	80000.0	155853.627327	1.0	4706124.0	4706123.0
WorkExp	1741.0	12.427915	10.0	9.870256	1.0	50.0	49.0
YearsCode	1741.0	15.668007	13.0	10.498279	1.0	60.0	59.0
JobSat	1189.0	7.229605	8.0	1.953224	0.0	10.0	10.0

Fuente: Elaboración propia

El resumen numérico muestra que `ConvertedCompYearly` presenta una gran dispersión, con una media de 101.907,74 y una mediana de 80.000. La diferencia entre ambas medidas, junto con un rango muy amplio, confirma la presencia de valores extremos altos en la compensación anual.


En `WorkExp`, la media es de 12,42 años y la mediana de 10 años, lo que indica una muestra con experiencia laboral media, aunque con presencia de perfiles muy senior. En `YearsCode`, tras la limpieza inicial, se obtienen 1741 valores válidos, con una media de 15,67 años y un máximo de 60 años.

Por último, `JobSat` presenta 1190 valores válidos, debido a la existencia de valores nulos. Su media de 7,23 y mediana de 8 indican una satisfacción laboral generalmente alta entre las personas que respondieron esta variable.

5.2. Análisis bivariente

Para la hipótesis 1, se analizará la relación entre la edad y el salario anual mediante estadísticas descriptivas y visualizaciones. El objetivo será comprobar si existe una tendencia positiva entre la edad y el incremento salarial.

Gráfico 5. Median salary by age group



Fuente: Elaboración propia.


Los resultados muestran una tendencia general positiva entre la edad y el salario anual. La mediana salarial aumenta desde los 20.883 en el grupo de 18-24 años hasta los 108.913 en el grupo de 45-54 años. El grupo de 65 años o más presenta la mediana más alta, con 130.210, aunque debe interpretarse con cautela debido a su bajo número de registros.

No obstante, la relación no es completamente lineal, ya que el grupo de 55-64 años presenta una mediana ligeramente inferior a la del grupo de 45-54 años. Además, existen valores atípicos salariales importantes, especialmente en los grupos de 25-34 y 35-44 años, por lo que la mediana resulta más representativa que la media.

En conjunto, la hipótesis H1 se acepta parcialmente: existe una relación positiva general entre edad y salario, aunque con excepciones y diferencias de tamaño muestral entre grupos.

Para la hipótesis 2, se estudiará cómo influye el nivel educativo en la situación laboral y/o en el salario. El objetivo será identificar si mayores niveles académicos están asociados a mejores oportunidades laborales y salariales.

Gráfico 6. Wage distribution by educational attainment



Fuente: Elaboración propia

Los resultados muestran una asociación positiva entre el nivel educativo y la empleabilidad. Los grupos con mayor cualificación académica presentan los porcentajes más altos de personas empleadas: máster con un 87,55%, grado universitario con un 85,38% y título profesional o doctorado con un 85,09%.

En cambio, los niveles educativos más bajos o menos definidos presentan porcentajes de empleo inferiores, como educación secundaria con un 67,39%, primaria con un 44,44% y la categoría `Other` con un 53,85%. Esto sugiere que una mayor cualificación académica está relacionada con mejores indicadores de empleabilidad dentro de la muestra.


Respecto al salario, también se observa una relación parcial. Los perfiles con `Professional degree` presentan la mayor mediana salarial, seguidos por máster y grado universitario. No obstante, algunas categorías tienen pocos registros o valores extremos que distorsionan la media, por lo que la mediana es una medida más fiable para la comparación.

En conjunto, la hipótesis H2 se acepta parcialmente: una mayor cualificación académica parece asociarse con mayor empleabilidad y mejores salarios, aunque existen diferencias muestrales y outliers que deben considerarse.



Para la hipótesis 3, se analizará la relación entre experiencia profesional, conocimientos técnicos y salario.

Gráfico 7. Average salary by years of experience



Fuente: Elaboración propia

Los resultados muestran una relación positiva entre la experiencia y el salario, aunque la correlación lineal es débil. La correlación entre `WorkExp` y `ConvertedCompYearly` es de 0,138, mientras que entre `YearsCode` y `ConvertedCompYearly` es de 0,172. Esto indica que la experiencia se asocia con salarios más altos, pero no explica por sí sola la variabilidad salarial.

Al agrupar la experiencia laboral por rangos, la tendencia resulta más clara. La mediana salarial aumenta desde 46.496 en el grupo de 0-5 años hasta 125.009,5 en el grupo de más de 36 años de experiencia. El salto más importante se observa entre los grupos de 0-5 y 6-10 años.


Los gráficos de dispersión muestran una elevada variabilidad salarial dentro de cada nivel de experiencia, lo que sugiere que otros factores, como país, industria, nivel educativo o tipo de puesto, también influyen en el salario.



En conjunto, la hipótesis H3 se acepta parcialmente: una mayor experiencia está asociada con salarios más altos, especialmente al analizar grupos de experiencia, aunque la relación individual no es fuerte.

Para la hipótesis 4, se comparan los salarios entre distintos tipos de empleo. El objetivo será comprobar si existen diferencias salariales significativas según el tipo de contratación.

Gráfico 8. Wage distribution by type of employment



Fuente: Elaboración propia

Los resultados no permiten confirmar claramente que los autónomos cobren más que los trabajadores por cuenta ajena. Aunque la media salarial de los autónomos o freelancers es superior a la de los empleados, con 117.258,8 frente a 102.326,4, la mediana salarial es ligeramente inferior en el grupo de autónomos: 76.520 frente a 81.210 en empleados.


Dado que la variable salarial presenta valores extremos, la mediana resulta más representativa que la media. El grupo de autónomos contiene un valor máximo muy elevado, de 4.706.124, que probablemente incrementa la media y distorsiona la comparación.



Además, existe una diferencia importante en el tamaño de los grupos, con 1469 empleados frente a 193 autónomos. Por tanto, la hipótesis H4 se rechaza parcialmente: los autónomos presentan una media más alta, pero no una mediana superior, por lo que no puede afirmarse de forma robusta que cobren más.

Para la hipótesis 5, se analizará la relación entre el uso de tecnologías relacionadas con Inteligencia Artificial y variables de empleabilidad. El objetivo será identificar si trabajar con tecnologías de IA supone ventajas laborales o económicas.

Gráfico 9. Salary distribution according to AISelect



Fuente: Elaboración propia

Los resultados no muestran una ventaja clara asociada a `AISelect` en términos salariales o de satisfacción laboral. La media salarial es prácticamente igual entre quienes responden `Yes` y quienes responden `No`, con 103.499,51 frente a 103.116,89. Además, la mediana salarial es mayor en el grupo `No`, con 85.925,5 frente a 78.959 en el grupo `Yes`.


En cuanto a la satisfacción laboral, las diferencias también son mínimas. Ambos grupos presentan una mediana de 8 y medias muy similares, 7,23 para `Yes` y 7,20 para `No`.



Por tanto, con las variables disponibles, la hipótesis H5 no se confirma. No se observa una relación clara entre responder afirmativamente en `AISelect` y obtener mejores indicadores salariales o de satisfacción laboral. Además, debe tenerse en cuenta que `AISelect` no necesariamente mide trabajar directamente con IA, por lo que la interpretación debe hacerse con cautela.

Para la hipótesis 6, se estudiará cómo varía el salario según la industria o sector empresarial. El objetivo será detectar qué industrias ofrecen mejores condiciones salariales para perfiles Data.

Gráfico 10. Ranking of industries by median salary



Fuente: Elaboración propia

Los resultados muestran diferencias salariales relevantes entre industrias, por lo que la hipótesis H6 se acepta. La mediana salarial varía de forma notable según el sector, desde los 62.648 en `Manufacturing` hasta los 105.060 en `Insurance`.

Las industrias con mayores medianas salariales son `Insurance`, `Healthcare`, `Computer Systems Design and Services`, `Energy` y `Government`. En cambio, sectores como `Manufacturing`, `Higher Education`, `Transportation, or Supply Chain`, `Banking/Financial Services` y `Software Development` presentan medianas más bajas.



También se observa que algunas industrias tienen medias muy superiores a sus medianas, como `Transportation, or Supply Chain`, lo que indica la presencia de valores salariales extremos que elevan la media. Por este motivo, la mediana resulta más adecuada para comparar los salarios entre sectores.

En conjunto, el tipo de industria parece influir en el salario anual, aunque las diferencias deben interpretarse considerando la dispersión interna y los valores atípicos presentes en cada sector.

5.3. Análisis multivariante

Gráfico 11. *Work experience, technical experience and salary*



Fuente: *Elaboración propia*

La experiencia muestra una relación positiva con el salario, especialmente al agrupar por rangos. La mediana salarial pasa de 46.576 USD en perfiles de 0-5 años de experiencia a 127.616 USD en perfiles con 31 años o más.



La experiencia técnica (`YearsCode`) también se asocia con salarios más altos, y en el análisis multivariante aparece como una de las variables con mayor relación con el salario. La H3 se acepta parcialmente: la experiencia y los años programando ayudan a explicar salarios más altos, aunque no son los únicos factores.

6. Conclusiones

Este estudio concluye que la mayoría de las hipótesis se cumplen parcialmente, excepto la H4 y H5, que son hipótesis exploratorias.

En consecuencia, se confirma que los factores más influyentes en el salario son la educación académica, experiencias profesionales y técnicas. Luego, hay otros factores externos como la clase de industria, donde existen diferencias salariales. En último lugar, observamos que la edad puede tratarse de una variante más objetiva dentro del análisis, aun presentando una relación positiva con el salario.

7. Recomendaciones

En primer lugar, sería interesante estudiar además las diferentes herramientas en tendencia dentro del mercado, para conocer cuales son las más populares dentro del perfil de datos.

En segundo y último lugar, existe un gran potencial para realizar una comparativa entre 2024 y 2025 para estudiar un posible análisis predictivo del año actual o posteriores.